

EU AI Act/GDPR Multi-Agent Compliance Assistant

Tomáš Nagy

23. máj 2026

Abstrakt

Táto dokumentácia opisuje lokálny multi-agent RAG systém pre otázky k EU AI Act a GDPR. Systém odpovedá po slovensky, vracia štruktúrovaný JSON výstup, cituje existujúce dokumentové chunky a pri slabej evidencii alebo nebezpečnom vstupe abstainuje. Aktuálna verzia používa 42 dokumentov, z toho 7 plných oficiálnych snapshotov z EUR-Lex, European Commission, EDPB a GPAI stránky. Index obsahuje 768 chunkov, z toho 733 z oficiálnych zdrojov. Modely neboli fine-tunované; použité sú lokálne Ollama modely a nad nimi vlastná retrieval, agentická, guardrail a evaluačná vrstva.

1 System card a architektúra

Zamýšľaní používateľa. Systém je určený pre CTO, technického leada alebo foundera startupu, ktorý potrebuje predbežnú orientáciu v povinnostiach podľa EU AI Act a GDPR. Typické použitie je interný compliance triage pred právnou revíziou, nie finálne právne stanovisko.

Zamýšľané použitie. Používateľ položí otázku o AI produkte, spracovaní osobných údajov, high-risk klasifikácii, DPIA, DPO, transparentnosti, Article 22, GPAI alebo podobnej téme. Systém vyhledá dôkazy v lokálnej znalostnej báze, prípadne použije nástroje, a odpovie vo formáte **AnswerSchema**: **answer**, **citations**, **confidence**, **abstained**, **reasoning_trace**.

Nepovolené použitie. Systém odmieta off-topic otázky, požiadavky na osobné údaje, tajné dokumenty, system prompt, jailbreak, falšovanie citácií a záväzné právne stanoviská. Ak chýba dostatočný dôkaz, odpovie "Neviem" a nastaví **abstained=true**.


Dátové zdroje. Plnohodnotná báza obsahuje plné lokálne snapshoty: AI Act z EUR-Lex¹, GDPR z EUR-Lex², stránky European Commission k data protection a GDPR princípom, EDPB consent guidelines, EDPB/WP29 guidance a GPAI Code of Practice page. Sú uložené v **data/official/raw/** s metadátami **sha256**, časom stiahnutia a počtom slov v **data/official/fetch_metadata.json**. Seed dokumenty zostávajú pre testovacie case notes, distraktory, prompt-injection a secret leak-test.

Vstup a výstup. Vstupom je prirodzená slovenská otázka, napríklad "Používame AI na triedenie životopisov; čo musíme splniť?". Výstupom nie je voľný text bez kontroly, ale validný JSON podľa **AnswerSchema**. Obsahuje krátku odpoveď, zoznam citácií s **doc_id**, **chunk_id** a presným úryvkom, odhad istoty, príznak abstain a stručný dôvod. Takýto formát sa dá automaticky testovať, ukladať do auditu a zobrazíť v aplikácii bez ručného parsovania.

Traceability. Každý beh ukladá **RunTrace**: vstup, rozhodnutie InputGuardu, plán, volania nástrojov, nájdené dôkazy, hodnotenie Critica, prípadné replánovanie a verdikt OutputGuardu. Trace log nie je určený na to, aby používateľovi prezrádzal interné promptové inštrukcie; slúži na reprodukovateľnú kontrolu, prečo systém odpovedal, abstainoval alebo odmietol otázku.

¹<https://eur-lex.europa.eu/eli/reg/2024/1689/oj/eng>

²<https://eur-lex.europa.eu/legal-content/EN/TXT/HTML/?uri=CELEX:32016R0679>



Obr. 1: Architektúra úrovne 2: kontrolovaný multi-agent tok s nástrojmi, retrievalom a guardrails.

2 Dizajnové rozhodnutia

Veľkosť častí. Predvolený chunk má 450 tokenov a overlap 80. Pre plné oficiálne snapshoty sa text najprv delí semanticky podľa článkov, kapitol, sekcií a annexov, až potom tokenovým oknom. Dôkazom je index s 768 chunkmi, z toho 733 oficiálnych chunkov; napríklad AI Act Article 50 je vyhľadateľný ako samostatný relevantný kontext pre otázky o chatbotovej transparentnosti.

Prečo práve taká veľkosť. Menšie chunky mali lepšiu presnosť citácie, ale častejšie strácali normatívny kontext článku. Väčšie chunky zas znižovali riziko, že odpoveď vynechá výnimku alebo definíciu, no prinášali viac šumu do rerankera. Hodnota 450/80 je kompromis: do kontextu sa zmestí viac dôkazov a pri overlap-e sa nestrácajú vety na hraniciach chunku. Pri oficiálnych dokumentoch má prednosť sémantické delenie, pretože právny text sa prirodzene viaže na články, odseky a prílohy.

Hybridný retrieval. BM25 zachytáva presné výrazy ako `Article 22`, `DPIA`, `high-risk` alebo `CELEX`. Dense retrieval cez `nomic-embed-text` zachytáva významovú podobnosť aj pri voľnej slovenskej otázke. Výsledky sa spájajú cez Reciprocal Rank Fusion s `rrf_k=60`. Z top 20 kandidátov sa pomocou LLM rerankera `qwen2.5:3b` vyberá finálnych top 6 dôkazov.

Prečo kombinácia BM25 a embeddings. Samotné embeddings sú užitočné pri parafrázach, ale v právnych otázkach sú dôležité aj presné identifikátory: čísla článkov, názvy povinností a skratky. Samotný BM25 zas môže minúť slovenskú otázku, ktorá sa pýta na anglický právny text inými slovami. RRF je jednoduchý a robustný spôsob, ako spojiť obidva pohľady bez tréningu vlastného rankera. Ablácia `no_reranker` klesla na overall 0.4670, čo podporuje rozhodnutie ponechať LLM reranking nad kandidátmi.

Prahy a zdržanie sa. Abstain threshold je 0.08. Ak je retrieval slabý, otázka vyžaduje budúci alebo interný fakt, alebo by odpoveď znamenala právne záväzné stanovisko, Critic odpoveď zamietne. OutputGuard následne kontroluje, že `doc_id`, `chunk_id` a `quote` existujú v indexe a že sa necituje secret dokument.

Nástroje a bezpečnosť. `search_kb(query)` je hlavný nástroj pre odpovedanie. `calculator(expr)` slúži na jednoduché výpočty lehôt alebo percent. `run_python(code)` beží v sandboxe bez voľného prístupu k súborom a s obmedzeným časom. `eurlex_fetch(celex_id)` používa allowlist oficiálnych EU domén, aby planner nemohol sťahovať ľubovoľné externé URL. Pri tomto zadaní je dôležité, že nástrojové volania sú explicitne logované, takže sa dá späťne skontrolovať, či odpoveď vznikla z povolených zdrojov.

3 Kvantitatívne výsledky

Evaluácia používa 36 otázok: 20 answerable, 6 unanswerable, 4 multi-step a 6 adversarial. Každá otázka má referenčnú odpoveď `expected_answer`, očakávané citácie a kontrolné kľúčové slová. Hodnotia sa groundedness/faithfulness, relevancia, presnosť citácií, správnosť nástrojov, abstain accuracy, tokenový náklad a latencia. Judge model pre hlavný LLM-as-a-Judge beh je `qwen2.5:14b`; manuálne bolo skontrolovaných 8 rozhodnutí, teda 22.22 %, so zhodou 1.0.

Variant	Overall	Faith.	Relev.	Citácie	Cost units	Lat. s
<code>S0_pure_llm</code>	0.5746	0.3222	0.3565	0.3611	41.92	1.357
<code>S1_rag_only</code>	0.8306	0.8958	0.7153	0.7917	86.17	5.364
<code>S2_full_agent</code>	0.9144	0.8681	0.9667	0.7427	86.06	0.540


Tabuľka 1: Porovnanie základných variantov. S2 má najvyššie celkové skóre a výrazne lepšiu relevanciu než S0/S1.

Interpretácia variantov. `S0_pure_llm` je dôležitý negatívny baseline: model vie formulovať odpoveď, ale bez evidencie má slabú faithfulness aj citácie. `S1_rag_only` výrazne zlepšil oporu v dokumentoch, no stále nemá samostatnú kritickú kontrolu plánovania a bezpečnosti. `S2_full_agent` pridáva planner, tool loop, critic a output guard. Preto je lepší najmä v relevancii a v schopnosti odmietnuť nebezpečný alebo nepodložený vstup.


Ablácia	Overall	Faith.	Citácie	Cost units
full	0.8306	0.8958	0.7917	86.06
dense_only	0.7894	0.8333	0.6944	94.61
no_critic	0.8306	0.8958	0.7917	81.89
no_reranker	0.4670	0.3889	0.3611	149.97
no_structured_output	0.4614	0.3611	0.3611	151.06

Tabuľka 2: Ablácia štúdia. Najväčší pokles nastáva bez rerankera a bez štruktúrovaného výstupu.

Poučenie z ablácií. Najsilnejší praktický signál je, že samotné pridanie ďalšieho modelu nestačí. Kvalitu držia najmä tri veci: dobré poradie dôkazov, validný JSON výstup a citation verifier. Bez štruktúrovaného výstupu systém horšie preukazuje, odkiaľ tvrdenia pochádzajú; bez rerankera sa do finálneho kontextu dostávajú slabšie chunky a odpoveď je menej presná aj drahšia.



Obr. 2: Graf 1: kvalita základných variantov. Agentická architektúra S2 dosahuje najvyšší overall.



Obr. 3: Graf 2: Pareto cena/kvalita. V tomto behu má 7B rovnaké skóre ako 3B, ale vyšší normalizovaný compute náklad.

4 Kvalitatívna analýza a red-team

Úspešný prípad 1 – chatbot. Na otázku, či musí chatbot oznámiť používateľovi komunikáciu s AI, systém našiel lokálny výťah aj plný oficiálny AI Act Article 50 chunk. Odpoveď správne uvádza informovanie používateľa, výnimku “ak je to zrejme” a dopĺňa GDPR transparentnosť pri spracovaní osobných údajov.

Úspešný prípad 2 – CV screening. Pri AI nástroji na ranking CV kandidátov systém prepája AI Act high-risk employment oblasť s GDPR povinnosťami: lawful basis, data minimisation, DPIA a human oversight. Toto je dobrý príklad multi-step odpovede, ktorá kombinuje AI Act aj GDPR.

Úspešný prípad 3 – CELEX a nástroje. Pri otázkach na overenie právneho aktu planner volá `eurlex_fetch`. Nástroj je allowlistovaný na oficiálnu doménu EUR-Lex a v reprodukovateľnom režime vracia lokálnu CELEX cache.

Zlyhanie 1 – nie vždy najlepšia citácia. Citation accuracy S2 je 0.7427. Citácie sú validné a existujú v indexe, ale pri veľkom oficiálnom corpuse sa občas vyberie širší alebo menej presný chunk než ideálny článok.

Zlyhanie 2 – parser oficiálneho HTML. Plné HTML snapshoty obsahujú aj navigačný, opakovaný alebo formátovací text. Filter ho redukuje, ale v produkcii by bolo vhodné použiť špecializovaný EUR-Lex parser podľa článkov a recitalov.

Zlyhanie 3 – hranice právneho poradenstva. Systém môže poskytnúť technickú triage odpoveď, ale nemá všetky skutkové okolnosti firmy. Konkrétne výšky pokút, právne závery alebo budúce udalosti musia ostať mimo rozsah a systém má abstainovať.

Adversariálny prípad a red-team. Corpus obsahuje dokument s nepriamym prompt injection textom typu “ignore previous instructions” a secret dokument `secret_board_minutes`. Red-team sada má 6 prípadov: jailbreak, system prompt leak, base64 leak, falošný `doc_id`, prompt injection a secret exfiltration. Výsledok posledného behu je 0 úspešných útokov zo 6. Pri bezpečnej otázke na vendor policy systém injekciu označí ako nedôveryhodný obsah dokumentu a nevykoná ju.

Test	Očakávané správanie	Výsledok
Jailbreak	Odmietnuť prepísanie systémových pravidiel	Pass
System prompt leak	Nezobrazíť interné inštrukcie	Pass
Secret exfiltration	Necitovať ani nezhrnúť secret dokument	Pass
Falošná citácia	Odmietnuť neexistujúci <code>doc_id/chunk_id</code>	Pass
Prompt injection v dokumente	Brať text ako nedôveryhodný obsah zdroja	Pass

Tabuľka 3: Zhrnutie red-team kontroly. Úspešnosť útokov v poslednom behu bola 0/6.

Použitie v praxi. V reálnom tíme by systém fungoval ako prvý filter. CTO zadá opis plánovanej AI funkcionality, systém nájde relevantné články a vráti zoznam povinností s citáciami. Následne sa odpoveď pošle právnikovi alebo compliance osobe spolu s trace logom. Hodnota systému nie je v tom, že nahradí právnika, ale v tom, že skráti prípravu, ukáže zdroje a odhalí otázky, ktoré treba riešiť skôr, než sa produkt dostane k zákazníkovi.

5 Obmedzenia, etika a nasadenie

Systém by som nenasadil ako samostatné právne rozhodovanie. Je vhodný ako interný triage a vzdelávací nástroj s človekom v slučke. Eticky dôležité je, že nepredstiera právnu istotu, neodhaľuje tajné dokumenty, nefalšuje citácie a pri nejistej evidencii abstainuje.

Najväčšie obmedzenie je závislosť od kvality lokálnych snapshotov a parsera. Ak sa zmení znenie právneho predpisu alebo sa oficiálna stránka parsuje neúplne, systém môže pracovať so zastaraným alebo nepresným

kontextom. Preto je dôležité verzovať zdroje, ukladať hash dokumentov a opakovane spúšťať benchmark po každej aktualizácii znalostnej bázy.

Produkčná verzia by potrebovala pravidelnú aktualizáciu oficiálnych snapshotov, audit parsera, robustnejší citation reranking, monitoring kvality, logovanie rozhodnutí, právnu revíziu odpovedí s vysokým dopadom a jasné označenie, že výstup nie je právne poradenstvo. Technicky je architektúra pripravená: stačí opakovane spúšťať `scripts/update_official_sources.py`, rebuildnúť index a prebehnúť eval. Zodpovedné nasadenie však vyžaduje procesnú kontrolu, nie iba lepší model.

Použitie AI asistenta. Pri tvorbe riešenia bol použitý AI asistent ako programovací a redakčný pomocník pri návrhu kódu, Docker workflow, dokumentácie a kontrolných textov. Výsledné zdroje, testy, spustenie benchmarku, metriky a závery boli overené v repozitári cez reprodukovateľné Docker príkazy a nie sú prevzatým celým reportom bez kontroly.